정책 판정관 J-Verdict 결과 설명자료

문제 정의 · Agent 구조 · 기능 · 실행 결과 · 검증과 한계 · 센터 활용 방안

2026 제주 AI·빅데이터 활용 AI Agent 개발 챌린지 · 참가자 신재우 · 2026-11-06 실행 기준

웹 데모 https://jverdict.streamlit.app · 소스 https://github.com/13JVV/jverdict

---

0. 한 장 요약

정책 판정관은 "정책이 효과가 있었는가"를 스스로 설계·검증해 판정하고, 근거가 부족하면 결론을 미루는 AI Agent입니다. 제주데이터허브 공개 데이터로 실제 정책 4건과 정답을 아는 합성데이터 1건에 적용했습니다.

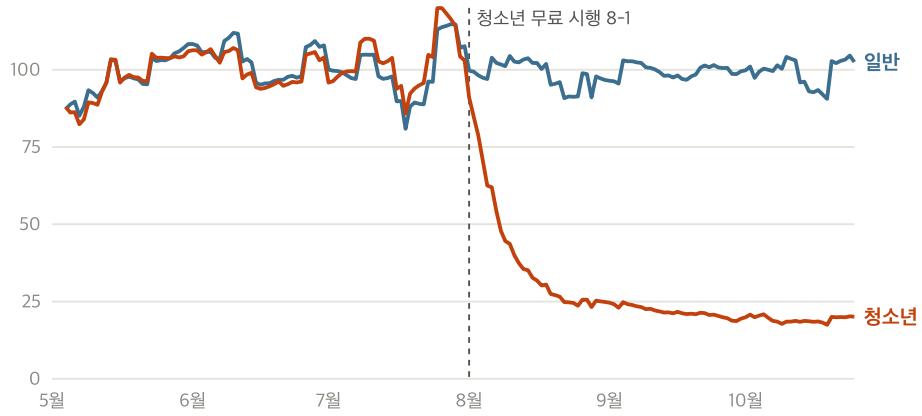
사례	단순 전후 비교	정책 판정관	판정 근거
A 청소년 버스 무료 (2025-08-01)	−76.0% → "정책 실패"	🔴 **판정 보류**	측정 단절 의심(강): 정책 대상만 급감, 도 발표와 8.3배 차이, 파일 4종 모두 같은 결론
B 1차 긴급재난지원금 (2020-05)	+5.1% → "효과 있음"	🔴 **판정 보류**	추정 −4.9%(판정 구간 −17.0% ~ +9.0%). 구분 가능한 최소 효과 ±16.0%로 검정력 부족
D 중국 단체관광 재개 (2023-08)	+105.8% → "효과 있음"	🔴 **판정 보류**	사전추세 크게 깨짐($p=9.9\times10^{-7}$). 추세를 보정하면 방향이 반대
E 사회적 거리두기 해제 (2022-04-18), 양성 대조	+94.8% → "효과 확실"	🔴 **판정 보류**	검증 C0~C4는 모두 통과. 그러나 기준 기간의 2021-08이 크게 벗어나 판정 구간 −66% ~ +2586%
C 합성데이터 (정답 +22.1%)	+35.5% (계절 때문에 과대)	🟢 **효과 있음 (증가)**	추정 +19.6%(판정 구간 +15.6% ~ +25.2%)가 정답을 포함. 검증 6개 모두 통과

지표	결과
틀린 결론을 피했는가	실데이터 4건 모두 단순 비교의 결론과 달랐습니다. 판정관은 판정 보류의 이유와 필요한 자료를 함께 냈습니다
정확도(합성 6,400회)	받아들일 만한 판정 95.7%, 없는 효과를 '효과 있음'이라 한 비율 2.4%, 방향을 반대로 판정 0%, 측정 단절 탐지 100%
재현성	실행 9건(오프라인 5, Claude 기록 4) 모두 수치·판정·판정서 문장 일치. Claude 기록은 API 없이 응답 기록으로 재실행
실행 환경	설치·인터넷·관리자 권한 없이 Windows에서 실행 `.bat`. 오프라인 실행 사례 5건 약 15초(개발 PC)
자동 시험	118개 통과(자료가 없는 공개본은 113개 통과, 자료 필요한 5개 건너뜀)

1. 문제 정의

1.1 무엇이 문제인가

데이터가 늘어날수록 "작년보다 늘었다/줄었다"는 숫자는 쉽게 나옵니다. 그 숫자가 정책 때문인지, 데이터 문제나 다른 요인 때문인지는 쉽게 가려지지 않습니다. 이번에 공개 데이터로 실제 정책 4건을 직접 분석해 보니, 단순 전후 비교는 **네 건 모두 틀린 결론**을 냈습니다.



일 승차 인원, 7일 평균, 시행 전(5~7월) 평균 = 100 · 자료: 제주데이터허브「이용자 유형별 버스정류소 이용 인원 현황」

단순 전후 비교라면

-76%

"무료화했더니 이용 급감, 정책 실패"로 보고

정책 판정관

판정 보류

측정 단절 의심(강)
· 대상만 급감, 일반은 그대로
· 도 발표와 8.3배 차이
· 같은 날 무료 확대된 어린이도 함께 급감

- **A 청소년 버스 무료화.** 시행일부터 청소년 승차가 76% 줄었습니다. 그대로 보고하면 "무료화 실패"입니다. 하지만 정책 대상(청소년·어린이)만 줄었고 다른 유형은 그대로였습니다. 도 발표(하루 약 22,783건)와 공개 데이터(약 2,745건)도 8.3배 차이가 납니다. 무료 승차가 공개 집계에서 빠진 것으로 보입니다.
- **B 재난지원금.** 비교군을 어떻게 잡느냐에 따라 방향이 뒤집힙니다(관광객과 비교하면 음수, 도민 내부 비교는 양수).
- **D 중국 단체관광.** 소비가 두 배로 늘었지만, 정책 전부터 이어지던 회복 추세가 만든 값이었습니다.
- **E 거리두기 해제.** 주점 소비가 크게 늘었지만, 비교 기준이 된 기간에 영업이 사실상 멈춘 달이 섞여 있었습니다.

1.2 누구를 위한 것인가

사용자	필요
도청 정책 부서	정책 효과를 보고하기 전에 숫자가 정책 효과인지 확인
도의회·정책보좌관	질의 전 "늘었다/줄었다"의 사실 확인
연구용역 발주 부서	과업지시서에 비교 집단·필요 기간을 미리 반영
제주빅데이터센터	정책 판정 서비스 운영, 공개 데이터 품질 감시

1.3 목표

1. 효과를 찾는 것만큼 **틀린 결론을 내지 않는 것**을 중요하게 봅니다.
2. 통계 지식이 없어도 질문 한 줄로 판정서를 받게 합니다.
3. 결론을 낼 수 없으면 **무엇이 있으면 낼 수 있는지**를 알려 줍니다.
4. 누가 다시 해도 같은 결과가 나오게 합니다.

2. Agent 구조

2.1 6개 역할과 가드레일

상태머신: 순서는 코드가 고정하고, 단계를 건너뛸 수 없습니다

① Policy Parser	② Data Scout	③ Design Agent	잠금	④ Executor	⑤ Skeptic	⑥ Reporter
질문 → 정책 카드	계열 정의·품질 점검	대조·기간·방법 선택	SHA-256·시각	추정·검증 세트	반론 세우고 검증	판정서 서술
사람 확인 1회	측정 단절이면 상한 '보류'	효과 값을 볼 수 없음	바꾸면 기록	오류 시 수정 3회	판정 하향 권한	숫자 대조 검사

원칙	구현
숫자는 툴이, 말은 LLM이	추정·검증·판정은 결정론적 코드(`jverdict.causal`). LLM은 설계 판단·반론·서술만. 판정서 속 숫자가 툴 결과에 없으면 다시 쓰게 함

원칙	구현
결과를 보기 전에 잠금	설계 단계의 툴은 시행일 이전 자료만 돌려줌. 잠금 전에는 효과 추정 툴을 부를 수 없음(코드가 거부)
데이터부터 의심	품질 점검은 LLM이 부르지 않아도 코드가 반드시 실행. 측정 단절이 의심되면 판정 상한을 '판정 보류'로 고정
보류도 결과물	필요한 자료, 다시 판정할 시점, 자료 요청 공문 초안을 함께 냄

2.2 툴

LLM이 골라 부르는 툴 (7개)	기능
`catalog_search`, `dataset_profile`	데이터셋 찾기, 집단별 요약(정책 전 기간만)
`official_stats`	대조할 공식 발표 수치
`quality_check`	측정 단절 진단과 커버리지 점검(반드시 1회)
`pick_controls`	대조 후보의 정책 전 유사도(상관·격차 변동·격차 추세)
`event_calendar`	같은 시기의 사건(명절·방학·코로나19·지원금·데이터 결측)
`extra_check`	반론 검증용 재추정(대체 대조·기간 변경·기간 제외·가짜 처치). 잠금 뒤에만

코드가 반드시 실행하는 단계는 다음과 같습니다.

- 잠금 검증
- 추정: 단절 시계열, 업종 패널 이중차분
- 검증 세트: C0 데이터 품질, C1 사전추세, C2a 시점 위약, C2b 공간 위약, C3 민감도, C4 이중 계산
- 검정력(MDE)
- 판정 규칙 v2
- 서술 숫자 대조
- 판정서와 재실행 기록

2.3 실행 방식

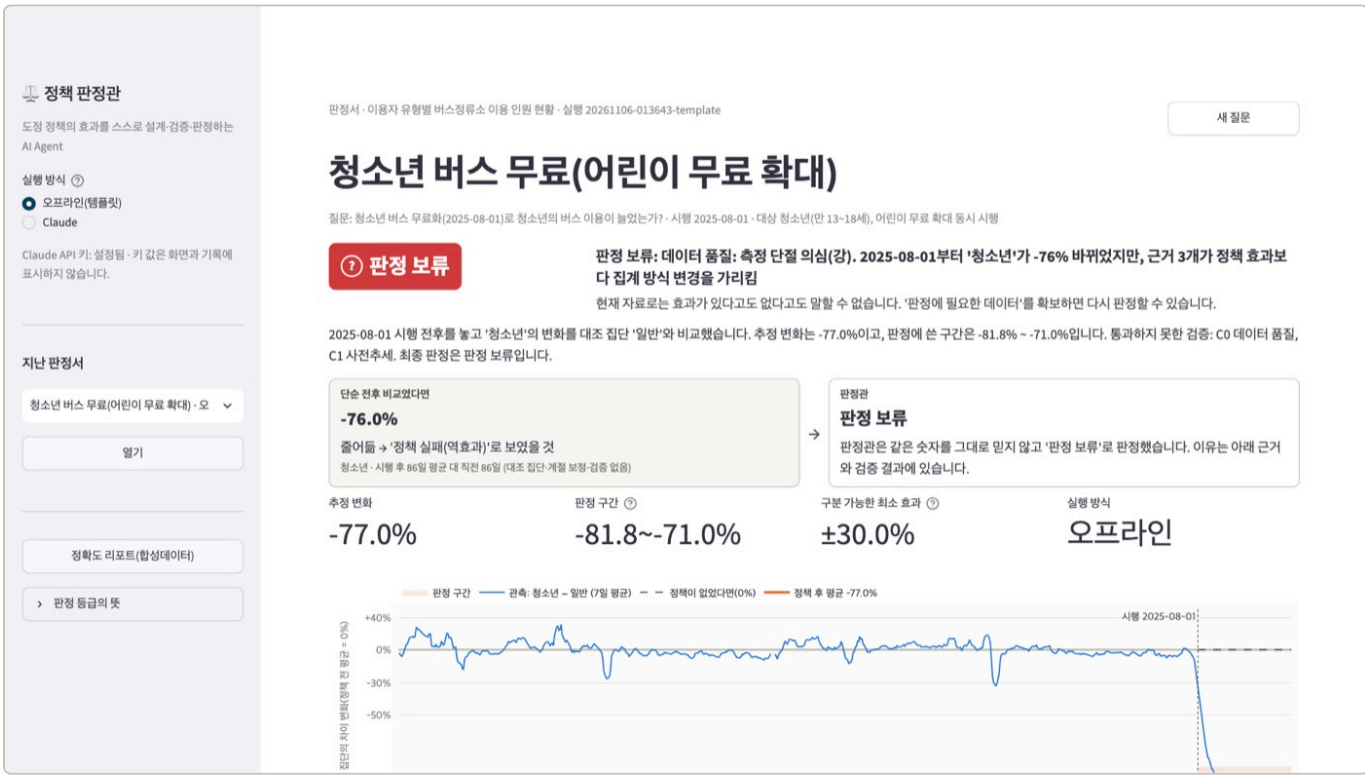
방식	판단 주체	필요한 것
오프라인(템플릿)	규칙 기반 Agent	없음(인터넷·키 불필요)
Claude	`claude-sonnet-5-5`(툴콜링)	API 키. 실행 1건 약 $0.09~0.13, 40~70초
재실행	저장된 응답 기록	없음(API를 부르지 않음)

Claude 단계가 실패하면 그 단계만 템플릿으로 자동 대체하고 기록에 남깁니다. API 크레딧이 떨어진 상황(사례 C)에서 실제로 확인했습니다.

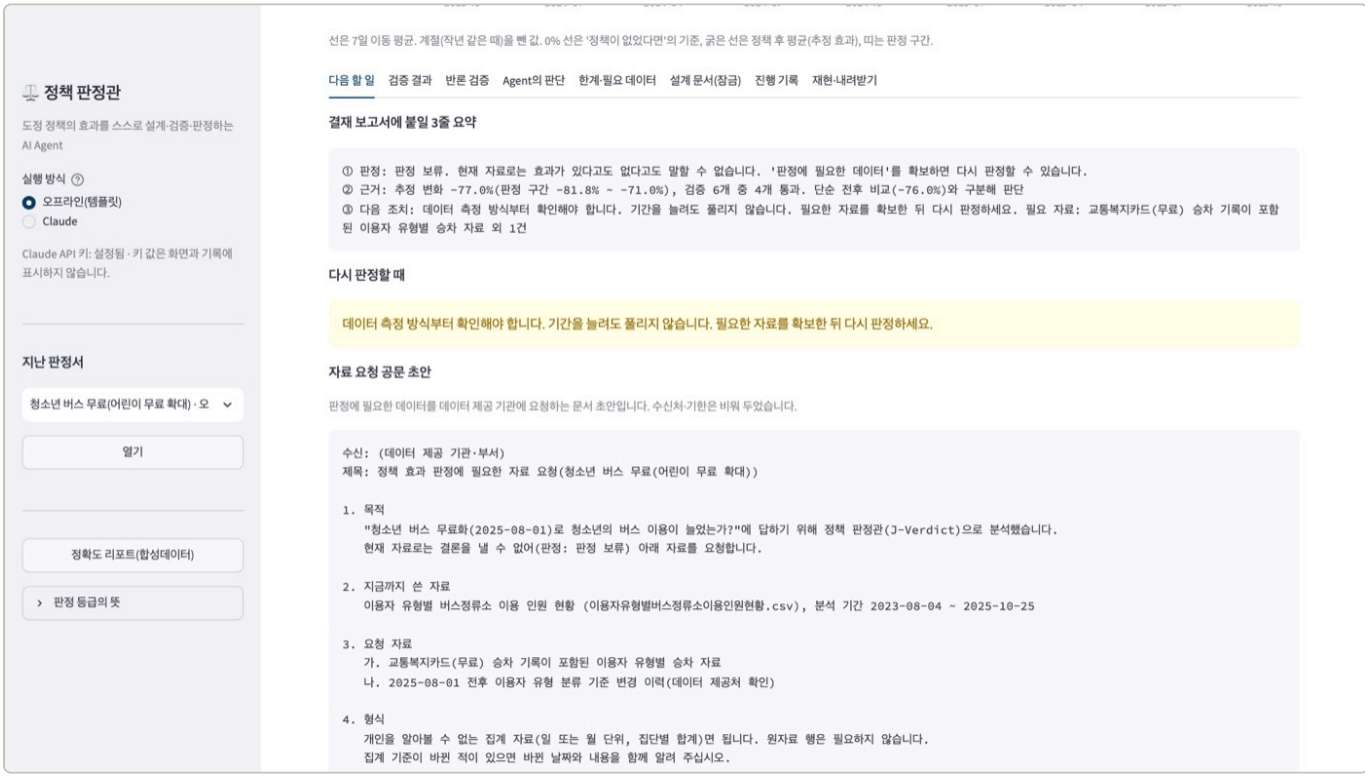
3. 주요 기능

기능	하는 일
질문으로 시작	예시 5개 또는 질문 입력. Claude 모드에서는 보도자료 문단도 정책 카드로
정책 카드 직접 만들기	데이터·시행일·대상만 고르면 새 정책도 API 키 없이 판정. 대조는 Design Agent가 정책 전 유사도로 고름
정책 카드 확인	사람이 한 번 확인한 뒤 설계를 잠금
판정서	4단계 판정, **단순 비교였다면 대 판정관**, 핵심 수치, 반사실 그래프, 위약검정 그림
다음 할 일	결재용 3줄 요약, 다시 판정할 시점, 자료 요청 공문 초안
Agent의 판단	단계마다 누가 무엇을 왜 정했는지와 툴 호출. Claude 기록을 키 없이 보고 오프라인 실행과 비교
재현·내려받기	같은 기록으로 다시 실행해 대조, 1장 판정서 PDF

기능	하는 일
정확도 리포트	합성데이터 정확도와 검정력 곡선
설치 점검(점검.bat)	이 PC에서 사례 5건을 새로 판정해 기록과 같은지 1~2분 안에 확인하고 보고서를 남김



판정서 맨 위(사례 A): 판정 보류, 단순 비교 –76% 대 판정관, 핵심 수치



다음 할 일: 결재용 3줄 요약, 다시 판정할 때, 자료 요청 공문 초안

4. 실행 결과

모든 수치는 `outputs/runs/<실행>/`의 기록에서 옮겼습니다. 요약표는 `outputs/runs/_summary.md`에 있습니다.

4.1 사례 A: 청소년 버스 무료화 (2025-08-01) → 판정 보류

- **데이터.** 이용자 유형별 버스정류소 이용 인원(일 단위). 대조 집단은 일반 승객이고, 계절 차분은 3년입니다.
- **결과.** 추정 −77.0%(판정 구간 −81.8% ~ −71.0%)로 크고 분명하지만, 방향이 정책 목적과 반대입니다.
- **측정 단절 진단: 의심(강).** 근거는 세 가지입니다.
- 방향 모순
- 비현실적 크기
- 외부 통계 불일치: 도 발표의 8.3배 차이
- **파일 4종이 같은 결론.**

파일	청소년 변화
정류소별	−76%
노선별	−63%
시간대별	−67%
월별 패널티	−85%

정책 대상이 아닌 경로·장애 유형에는 단절이 없습니다. - **시간대 모양.** 청소년 감소(일반 대비)가 통학 시간대(07~09시 −69%)만이 아니라 새벽(−80%)과 밤(−69%)까지 고릅니다. 이용 행동 변화보다 집계 누락에 가까운 모양입니다. - **필요한 데이터.** - 교통복지카드(무료) 승차 기록이 포함된 이용자 유형별 승차 자료 - 2025-08-01 전후 분류 기준 변경 이력 - **Claude 실행과 비교.** Claude는 대조로 '경로'를 골랐습니다(정책 전 상관 0.9868로 일반보다 높음). 추정 −75.6%, 판정은 같은 '보류'입니다. LLM 호출 9회, $0.128이었습니다.

4.2 사례 B: 1차 긴급재난지원금 (2020-05) → 판정 보류

- **설계.** 사전 등록 문서(`docs/prereg/case_relief2020_engine.md`)를 그대로 썼습니다. 대상은 도민 × 사용 가능 업종 24개, 대조는 도민 × 사용 불가 업종이고, 법인은 공간 위약으로 썼습니다.
- **결과.** 사용 기간(5~8월) 평균 −4.9%(판정 구간 −17.0% ~ +9.0%)입니다. 구분 가능한 최소 효과가 ±16.0%라 기준 효과 10%를 가릴 수 없습니다(검정력 부족). 시점 위약검정(C2a)도 통과하지 못했습니다.
- **해석.** 5월 단독은 +3.0%로 KDI 연구와 방향·시점이 맞습니다. 하지만 월 단위·단일 카드사 자료로는 확정할 수 없습니다. 첫 분석의 판정 후보였던 '조건부'는 사전 등록한 엔진 재판정으로 '보류'가 되었습니다.
- **다시 판정할 때.** 끝난 정책이라 기다려도 관측이 늘지 않습니다. 일 단위나 전체 카드사 자료가 필요합니다.

4.3 사례 D: 중국 단체관광 재개 (2023-08-10) → 판정 보류

- **설계.** 사전 등록 문서(수정 1)를 썼습니다. 업종 패널 이중차분이고, 대조는 일본·동남아·기타외국입니다. 2019년 같은 달 기준이고, 업종 × 월 고정효과를 넣었습니다.
- **결과.** 주분석 +170.9%였지만 사전추세가 크게 깨졌습니다($p=9.9\times10^{-7}$). 추세를 보정하면 −75.8%로 방향이 반대입니다. 민감도(C3)도 실패했습니다.
- **해석.** 정책 시점의 단절이 아니라 기존 회복 추세가 만든 값입니다.
- **데이터 문제.** 2023-05~06 외국인 4개 집단 결측을 자동으로 찾았습니다.
- **판정 기록.** 원래 등록(규칙 v1) 판정과 수정안 판정을 나란히 기록합니다.
- **Claude 실행.** 반론을 4개 세웠습니다(재개 직후 단기 효과, 일본 단독 비교, 사전 기간 말 회복기 제외 등). 판정은 같은 '보류'입니다.

4.4 사례 E: 사회적 거리두기 전면 해제 (2022-04-18) → 판정 보류 (양성 대조)

- **왜 했나.** 실데이터에서 '효과 있음'이 한 번도 나오지 않아서, 효과가 있다고 널리 알려진 정책을 일부러 골랐습니다.
- **사전 등록.** `docs/prereg/case_distancing_2022.md`, 2026-11-06 00:30 잠금. 결과를 본 뒤 설계는 바꾸지 않았습니다.
- **설계.** 제주도민 × 주점(일반유흥·기타 주점)을 식료품 소매 5업종과 비교했습니다. 사전 12개월, 사후 6개월입니다. 과거 같은 달도 방역 기간이라 계절 차분은 쓰지 않았고, 가짜 시행일은 방역 기간 밖에서만 뽑았습니다.
- **결과.** 추정 +201.2%였고 검증 C0~C4는 모두 통과했습니다. 시점 위약에서도 가짜 34개 중 실제가 가장 컸습니다(p=0.029). 그러나 판정 구간이 −66.2% ~ +2586.4%로 넓어 규칙상 '보류'입니다.

- **원인.** 기준 기간 안의 2021-08(거리두기 4단계 무렵)에 주점 결제가 거의 사라졌습니다. 대상/대조 로그 격차로 보면 사전 중앙값보다 4.44 낮습니다. 이 한 달이 기준선과 분산을 함께 흔들었습니다.
- **판정서의 설명.** "사후 5524개월 필요" 같은 엉뚱한 안내 대신 "기준 기간의 이상 시점(2021-08)을 먼저 확인"이라고 쓰도록 보강했습니다.
- **보조 확인(사전 등록 밖, 판정에 쓰지 않음).** 다른 파일(시간대별 카드 이용 금액)에서 도민 소비 중 밤 시간대 비중을 봤습니다.

시점	밤 비중
2019년(코로나 전)	11.5%
해제 직전	4.4%
해제 뒤	9.6%

늦은 시간 소비가 해제 뒤 두 배 넘게 회복했습니다. 따라서 E의 '보류'는 효과가 없다는 뜻이 아닙니다. 기준 기간이 오염되어 판정관이 보수적으로 멈춘 것입니다. 실데이터에서 '효과 있음'을 낸 사례는 아직 없고, 이 점을 그대로 보고합니다.

4.5 사례 C: 합성데이터 (정답 +22.1%) → 효과 있음(증가)

- **데이터.** 실데이터 변동에 맞춘 합성 버스 데이터입니다. 2024-03-04에 청소년 +22.1%를 심어 두었고, 정답은 판정 뒤에만 공개합니다.
- **결과.** 추정 +19.6%(판정 구간 +15.6% ~ +25.2%)로 판정 구간이 정답을 포함합니다. 검증 6개 모두 통과했고, 구분 가능한 최소 효과는 ±6.0%입니다.
- **단순 전후 비교와의 차이.** 단순 비교는 +35.5%입니다. 시행 전후 계절 차이까지 효과로 셌기 때문입니다.

5. 검증과 한계

5.1 정확도 (정답을 아는 합성데이터)

항목	결과	규모
받아들일 만한 판정(정답에 비추어 틀리지 않음)	95.7%	인과 판정 12개 시나리오 × 200회 = 2,400회
효과가 없는데 '효과 있음'	2.4%	같은 2,400회
효과가 있는데 '효과 없음'	0.1%	같은 2,400회
방향을 반대로	0%	같은 2,400회
검정력 곡선	+5% 효과 41.5%, +10.5% 79% '효과 있음'	1,400회
측정 단절 탐지(60~90% 누락)	100%	품질 점검 13개 시나리오 × 200회 = 2,600회
실제 효과를 측정 단절로 잘못 봄	0.125%	같은 2,600회
가장 약한 지점: 기존 분류 사이 이동	'의심' 11%, '확인 필요' 포함 67%	같은 2,600회

정확도 측정에서 드러난 문제(대조 집단에만 생긴 사건을 효과로 오판 등)는 판정 규칙 v2로 고쳤습니다. 변경 이력은 코드 안에 기록했습니다.

5.2 재현성

- **재실행 대조.** 실행 9건 모두 핵심 수치·판정·판정서 문장이 같습니다. Claude 기록 4건은 API 없이 저장된 응답으로 재실행합니다.
- **지문 기록.** 판정마다 다음을 남깁니다.
- 데이터 지문(원본·가공 파일 SHA-256)
- 코드 지문
- 사전 등록 지문
- 시드
- LLM 응답 기록

- 사건 달력 기준일
- **보강한 문제.**
- 같은 PC에서도 앞서 실행한 작업에 따라 부동소수 마지막 비트가 달라졌습니다 → 정규화 지문으로 해결
- 사례를 하나 추가하자 기존 Claude 기록의 프롬프트가 바뀌었습니다 → 참고 사례 목록 고정으로 해결
- 사건 달력이 늘어나 기존 기록과 어긋났습니다 → 원래 실행 날짜의 달력을 쓰게 해 해결
- **설치 점검.** 압축을 새로 푼 상태를 흉내 낸 점검에서 실패 0건이었습니다. Windows 실제 PC 시험은 최종 묶음으로 11-17에 하며, 결과는 제출 전 이 문서에 반영합니다.

5.3 한계

한계	대응
실데이터 4건 모두 '보류', '효과 있음' 실데이터 사례 없음	결과에 맞춰 설계를 바꾸지 않음. '효과 있음'의 작동은 합성데이터로 증명. E의 보조 확인은 효과의 존재를 시사
공개 데이터의 해상도(월 단위·단일 카드사)가 낮아 검정력 부족	구분 가능한 최소 효과를 함께 보고. 센터 일 단위 자료 연계를 확장 계획에 둠
측정 단절·결측의 원인을 데이터만으로 확인할 수 없음	'의심'으로 표기하고 제공처 확인 방법을 판정서·품질 점검 보고에 적음
평행추세 등 인과 가정은 검정으로 완전히 증명할 수 없음	판정서마다 '이 분석이 말할 수 없는 것' 문단
사례 B의 비교군 교체는 데이터를 본 뒤의 결정	사후 결정임을 명시하고, 엔진 재판정은 설계를 먼저 잠근 뒤 실행(열람 사실 고지)
오프라인 모드는 문장으로 된 새 질문을 해석하지 못함	정책 카드 직접 만들기로 새 정책을 판정
공개 웹 데모에는 실데이터 없음	허브 재배포 조건 미확인. 기록된 판정서와 합성데이터 판정만, 실데이터는 설치 묶음

6. 센터 활용 방안

6.1 바로 쓸 수 있는 것

1. **정책 판정 서비스.** 부서가 질문이나 정책 카드를 보내면 센터가 판정서를 발행합니다. 보류이면 자료 요청 공문 초안과 다시 판정할 시점을 함께 돌려줍니다. 판정마다 잠긴 설계와 재실행 기록이 남습니다. 그래서 감사·검증 때 "같은 판정 다시 만들기"가 됩니다.
2. **공개 데이터 품질 감시.** 새 데이터를 올릴 때 같은 품질 점검(`jverdict.quality`)을 돌리면, 집계 방식이 바뀐 날을 공개 전에 찾을 수 있습니다. 이번에 찾은 5건은 「허브 데이터 품질 점검 보고」로 별첨했습니다. - 청소년 무료화 시점의 측정 단절 - 2025-01 '기타' 신설 - 104일 결측 - 부분 집계 126일 - 외국인 2개월 결측
3. **연구용역 사전 설계.** 사전 등록 문서를 과업 산출물로 요구하고, 필요한 비교 집단·기간을 과업지시서에 미리 넣습니다.

6.2 확장

확장	내용
센터 내부 데이터 연계	일 단위 쓰레기·날씨·카드 전체 자료로 검정력 향상. 예: 재활용품 요일별 배출제(2027 존폐 결정)·상시배출 시범의 사전 평가 설계
추정 방법	합성통제, 회귀불연속, 집단별(연령·지역) 이질적 효과
지역 단위	정류소 → 읍면동 매핑(정류소 API 확보 완료)으로 지역 정책 판정
운영	판정 이력 관리, 부서별 요청·공유, 재판정 알림

부록. 실행과 파일

하려는 것	방법
설치 점검	점검`.bat` → `outputs\doctor\점검_*.txt`

하려는 것	방법
화면	실행`.bat` → http://localhost:8501
사례 전부 판정·대조	`runtime\python.exe -m jverdict.agent.demo`
같은 판정 다시 만들기	`runtime\python.exe -m jverdict.agent --replay outputs\runs\case-A-template`
판정 기록	`outputs\runs\case-*` (판정서 `verdict.pdf`)
사전 등록 문서	`docs\prereg\`
연구 기록(발견 F1~F13)	`docs\research\findings.md`
매뉴얼·명세	`docs\manual\`, `docs\spec\`