데이터 활용 명세

정책 판정관 J-Verdict · 사용 데이터, 출처·이용조건, 전처리·분석 흐름, 외부 데이터·오픈소스

작성: 신재우 · 2026-11-06 · 대상 제출물: 최종 결과물 zip

---

1. 요약

항목	내용
필수 데이터	제주데이터허브 공개 데이터 **8종 확보·점검, 그중 6종을 판정과 교차 점검에 사용** (대회 규칙: 1종 이상)
규모	버스 4종 약 2,997만 행, 카드 3종 약 4만 8천 행, 정류소 4,352곳
개인정보	모두 집계 데이터(일·월 × 유형·업종 합계). 개인을 알아볼 수 있는 항목 없음
외부로 보내는 데이터	Claude 모드에서만 집계 통계·스키마·분석 결과를 Claude API로 보냄. 원자료 행은 보내지 않음. 오프라인 모드는 외부 전송 없음
제출 zip에 넣는 것	가공 파일(파케이), 10MB 이하 원본 CSV(카드 3종 등), 원본·가공 파일 지문 기록. 1GB 버스 원본 2종은 넣지 않고 지문으로 같은 데이터임을 확인
공개 저장소·웹 데모	원본·가공 파일 모두 넣지 않음(재배포 조건 미확인). 판정 기록과 받는 방법만 공개

2. 사용 데이터 (제주데이터허브)

확인일 2026-11-06. 모두 허브에 로그인한 뒤 내려받았습니다. 허브 표기상 제공처는 제주빅데이터센터입니다.

#	허브 데이터명 (파일)	기간·단위	규모	쓰임	사용
1	이용자 유형별 버스정류소 이용 인원 현황 (이용자유형별버스정류소이용인원현황.csv)	2019-01-01 ~ 2025-10-25, 일	15,803,315행 · 624MB	사례 A 결과지표(이용자 유형별 일 승차). 측정 단절 탐지, 커버리지 점검(104일 결측, 부분 집계 126일, '기타' 신설 발견)	✔ 판정
2	일별 버스 승차 인원 수 현황 (일별버스승차인원수현황.csv)	2019-01-01 ~ 2025-10-19, 일	14,127,952행 · 498MB	사례 A 교차 점검(노선 기준 집계). Agent가 고를 수 있는 데이터셋	✔ 교차 점검
3	일별 시간대별 버스 승차 인원 수 현황 (일별시간대별버스승차인원수현황.csv)	2023-12-25 ~ 2025-10-26, 일 × 시간대	37,057행 · 1.5MB	사례 A 교차 점검(네 번째 파일). 시간대별 청소년 감소 모양	✔ 교차 점검
4	월별 버스 이용자 유형별 패널티 현황 (월별버스이용자유형별패널티현황.csv)	2018-06 ~ 2025-09, 월	3,622행 · 0.1MB	사례 A 교차 점검(월 이용자 수)	✔ 교차 점검
5	업종별 성별 카드 이용 정보 (업종별성별카드이용정보.csv, 허브 data/view/data/1048)	2018-01 ~ 2025-06, 월	28,255행 · 2.0MB	사례 B·D·E 결과지표(업종 × 이용자구분 월 금액). 커버리지 점검(외국인 2개월 결측 발견)	✔ 판정
6	시간대별 카드 이용 금액 현황 (시간대별카드이용금액현황.csv)	2018-01 ~ 2025-06, 월	8,673행 · 0.3MB	사례 E 보조 확인: 제주도민 밤 시간대 소비 비중(사전 등록 밖, 판정에 쓰지 않음)	✔ 보조
7	요일별 카드 이용 건수 비교 (요일별카드이용건수비교.csv)	2018-01 ~ 2025-06, 월	10,684행 · 0.4MB	구조만 확인. 이용자 구분(도민·관광객)이 없어 사례의 비교군을 만들 수 없음	사용 안 함
8	버스 정류소 기본 정보 (API, 허브 data/view/data/612)	조회 시점	4,352곳	정류소 ID·이름·좌표 확보. 읍면동 지역 분석은 확장 계획	확보만

파일 지문(SHA-256 앞 16자리). 원본과 가공 파일의 전체 지문은 `data/processed/_sources.json`에 있고, 판정마다 `manifest.json`에도 기록합니다.

파일	원본 지문
이용자유형별버스정류소이용인원현황.csv	`0eac15877892a93f`
일별버스승차인원수현황.csv	`7941dce63a51e923`
일별시간대별버스승차인원수현황.csv	`acecf3fa511c68de`
월별버스이용자유형별패널티현황.csv	`66e0b08d12acd5dd`
업종별성별카드이용정보.csv	`518cd18e78141ede`
시간대별카드이용금액현황.csv	`5e9103d29615273c`
요일별카드이용건수비교.csv	`7549728c3e5fe45e`
bus_stations.csv (정류소 API 저장본)	`d85fc7bc2015c741`

3. 이용조건과 권리

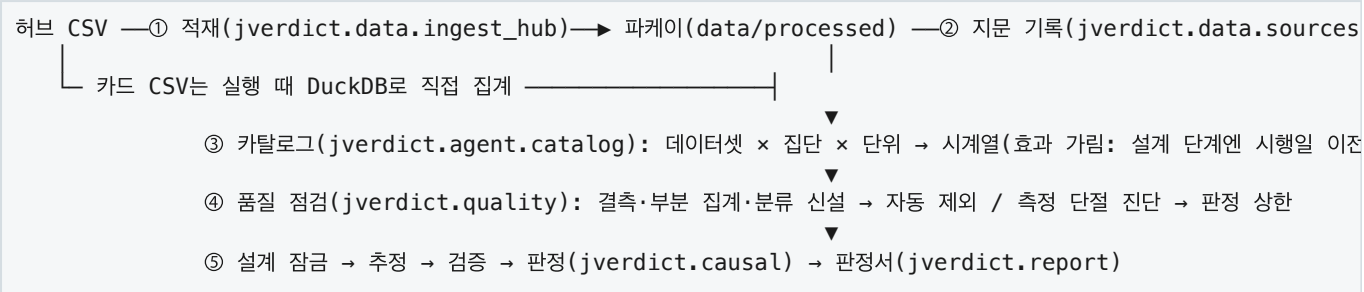
- **확인한 것.** 2026-11-06에 허브 데이터 상세 페이지(예: data/view/data/1048)를 다시 확인했습니다. 데이터별 이용허락 표시(공공누리 유형 등)나 재배포 조건은 따로 적혀 있지 않았습니다. 사이트의 이용약관 페이지 내용도 확인하지 못했습니다.
- **그래서 이렇게 씁니다.** 1. 대회 규칙에 따라 분석에 씁니다("제주빅데이터센터 또는 제주데이터허브 데이터 중 1종 이상"). 2. 제출 zip은 센터(데이터 제공처이자 대회 주관)에 내는 것이므로, 재현에 필요한 가공 파일과 작은 원본을 넣습니다. 3. 공개 저장소(GitHub)와 웹 데모에는 원본·가공 파일을 넣지 않습니다. 판정 기록(집계 비율·검정 결과)과 내려받는 방법만 공개합니다. 4. 모든 판정서와 문서에 출처(제주데이터허브, 데이터명)를 적습니다. 5. 카드 데이터는 비씨카드 실적이라 제주 전체 소비가 아닙니다. 절대 금액이 아니라 비율과 변화율로만 해석합니다.
- **확인 요청.** 재배포 조건은 허브 운영기관(제주데이터허브, 064-720-3735)에 확인하는 것이 맞습니다. 허용되면 웹 데모에도 실데이터를 넣을 수 있습니다.
- **결과물 귀속.** 대회 규칙에 따라 결과물은 제주빅데이터센터에 귀속되며 비영리 목적으로만 씁니다.

4. 보조 데이터 (허브 밖, 출처를 판정서에 기재)

자료	쓰임	출처
어린이·청소년 무료 이용 누적 483만 건(2025-08 ~ 2026-02), 카드 등록률 68.6%	사례 A 외부 통계 대조(공개 데이터와 8.3배 차이)	제주도 발표 인용 보도(트위그뉴스 2026-04-08)
「1차 긴급재난지원금 정책의 효과와 시사점」(2020-12)	사례 B 결과와 방향 비교	KDI
지원금 사용처 규정(사용 가능·불가 업종)	사례 B 업종 분류 근거 (`src/jverdict/cases/relief2020_sectors.csv`에 업종별 근거 기재)	행정안전부·제주도 발표 보도(2020-05)
중국 단체관광 허용(2023-08-10)	사례 D 시행일	중국 문화여유부 발표 보도
사회적 거리두기 전면 해제(2022-04-18), 실내 취식 허용(04-25)	사례 E 시행일·사건 달력	중앙재난안전대책본부 발표(2022-04-15) 보도
오미크론 정점(2022-03-17 신규 확진 약 62만 명)	사례 E 반론 검증(사건 달력)	질병관리청 발표 보도
설·추석 양력 날짜, 방학 기간(대략)	계절·명절 반론, 위약검정 제외	양력 환산 명절표, 일반 학사 일정

모든 보조 자료는 출처와 함께 `docs/research/facts.md`, `docs/research/findings.md`, `src/jverdict/agent/library.py`(사건 달력)에 기록했습니다.

5. 수집·전처리 흐름



1. **적재.** 정류소명에 따옴표 없는 쉼표가 섞여 있어 일반 CSV 파서 대신 파일별 정규식으로 줄 단위 파싱합니다. 버스 4종 2,997만 행을 거부 행 0건으로 적재했습니다(`data/processed/_ingest_report.json`). 날짜·정수형으로 바꾸고 파케이로 저장합니다.
2. **지문 기록.** 원본 CSV와 가공 파케이의 SHA-256·크기를 짝지어 기록합니다. 원본이 없는 PC에서는 가공 파일 지문을 대조해, 맞을 때만 기록된 원본 지문을 판정 기록에 씁니다.
3. **카드 정제.** - 성별을 합산합니다. - 업종명의 글자 깨짐('?')을 제거해 원래 업종에 합칩니다(예: '기타음?식료품위주종합소매업' → '기타음식료품위주종합소매업'). - 사례 B는 지원금 사용처 규정으로 43개 업종을 가능 24 / 불가 2 / 불확실 17로 나눴습니다. 불확실 업종은 주분석에서 빼고 민감도 분석에만 씁니다.
4. **품질 점검.** 다음을 자동으로 찾아 분석에서 뺍니다. - 전체 결측, 집단 결측 - 부분 집계일: 합계가 평소의 50% 미만이면서 집계 단위 수도 80% 미만인 날 - 분류 신설

정책 시점의 측정 단절이 의심되면 판정 상한을 '판정 보류'로 고정합니다. 5. **계절 처리.** 과거 같은 달(일 단위는 같은 요일)의 값을 빼는 계절 차분을 기본으로 씁니다. 사례 E는 과거 같은 달도 방역 기간이라 계절 차분 없이 사전 12개월(한 해 전체)을 쓰고, 그 이유를 사전 등록 문서에 적었습니다.

6. 분석 흐름 (Agent)

단계	하는 일	데이터
① 정책 카드	질문 → 정책·시행일·대상·결과지표	질문(또는 직접 만든 카드)
② 데이터 점검	계열 정의, 커버리지·측정 단절 진단(반드시 실행)	대상·대조 후보 계열
③ 비교 설계	대조 집단·기간·방법 선택. **효과 값을 볼 수 없음**(시행일 이전 자료만)	정책 전 요약
잠금	설계 문서 SHA-256·시각 기록	-
④ 추정	단절 시계열 또는 업종 패널 이중차분	잠긴 설계의 계열
⑤ 반론 검증	사전추세, 시점·공간 위약, 민감도, 이중 계산, 사건 달력 반론	같은 계열 + 다른 대조
⑥ 판정서	4단계 판정, 단순 비교 대비, 다음 할 일, 1장 PDF	분석 결과

산출물은 판정마다 `outputs/runs/<실행>/`에 남습니다: 정책 카드, 설계, 잠금 기록, 분석 결과, 반론, 판정서, manifest(데이터·코드 지문, LLM 응답 기록).

7. 외부 서비스와 오픈소스

구분	이름	용도	조건
외부 API(선택)	Claude API (`claude-sonnet-5-5`, Anthropic)	정책 카드 추출, 데이터 점검 계획, 설계 판단, 반론, 서술	사용자 API 키(.env). 없으면 오프라인 모드. 실행 1건 약 $0.1
외부 API(사전 1회)	제주데이터허브 정류소 API	정류소 기본 정보 저장	허브 프로젝트 키(.env). 실행 때는 필요 없음

구분	이름	용도	조건
실행 환경	Python 3.14.3 Windows 임베디드(python.org)	설치 없이 실행	PSF-2.0. SHA-256 대조
핵심 패키지	DuckDB 2.0.0 (MIT), pandas 3.1.0 (BSD-3), NumPy 2.5.4 (BSD-3 외), SciPy 1.18.1 (BSD), statsmodels 0.15.0 (BSD-3), PyArrow 26.0.0 (Apache-2.0), Streamlit 1.66.1 (Apache-2.0), Plotly 7.1.0 (MIT), Jinja2 3.1.6 (BSD), anthropic 2.3.0 (Apache-2.0)	적재·통계·화면·판정서	전체 59개와 라이선스는 `docs/spec/오픈소스_목록.md`
판정서 PDF	Google Chrome 또는 Microsoft Edge(PC에 있는 것)	HTML → PDF 인쇄	없으면 HTML로 저장

8. 재현 방법

```
# 자료가 있는 PC(제출 zip)
점검.bat                                    # 사례 5건을 새로 판정해 기록과 같은지 확인
python -m jverdict.agent --replay outputs/runs/case-A-template
# 원본부터 다시(허브에서 받은 CSV를 data/에 둔 뒤)
python -m jverdict.data.ingest_hub && python -m jverdict.data.sources
python -m jverdict.cases.quality_real       # 실데이터 품질 점검
python -m jverdict.agent.demo               # 사례 전부 판정 + 재실행 대조 + 판정서
```