제주데이터허브 공개 데이터 품질 점검 보고

정책 판정관 J-Verdict가 분석 중 자동으로 찾은 품질 이슈 5건과 확인 요청

받는 곳: 제주빅데이터센터(제주데이터허브 운영) · 작성: 신재우(2026 제주 AI·빅데이터 AI Agent 챌린지 참가자) · 2026-11-06

요약

정책 효과를 판정하려면 데이터가 정책 시점 앞뒤로 **같은 방식으로 집계되었는지**부터 확인해야 합니다. 정책 판정관은 효과를 추정하기 전에 이 점검을 반드시 실행합니다. 공개 파일 8종을 점검하는 과정에서 아래 5건을 찾았습니다.

원인은 데이터만으로는 확정할 수 없습니다. 그래서 모두 **'의심'** 단계로 적고, 확인 방법을 함께 드립니다.

#	데이터	이슈	기간	분석에 주는 영향	확인 요청
1	버스 4종(정류소별·노선별·시간대별·월별 패널티)	**청소년·어린이 승차가 무료화 시행일부터 대부분 사라짐**	2025-08-01 ~	"무료화로 청소년 이용 76% 감소"라는 잘못된 결론이 나올 수 있음	교통복지카드(무료) 승차가 이용자 유형 집계에 들어가는지, 분류 기준 변경 이력
2	버스 정류소별	**'기타' 분류 신설, 같은 날 어린이 감소**	2025-01-01 ~	어린이 감소를 정책·수요 변화로 오해할 수 있음	이용자 유형 분류 체계 변경 여부
3	버스 정류소별	**104일 전체 결측** 후 부분 집계	2022-08-12 ~ 11-23, 이후 11-24 ~ 12-07	이 기간이 걸친 분석은 값이 크게 왜곡됨	결측 사유, 원자료 보완 가능 여부
4	버스 정류소별	**짧은 부분 집계 117건(126일)**	2019 ~ 2025 곳곳	일 단위 분석에서 급감처럼 보임	부분 집계일 표시(플래그) 제공 가능 여부
5	업종별 성별 카드 이용	**외국인 4개 집단 2개월 동시 결측**	2023-05 ~ 06	외국인 관광 정책 분석의 사전 기간이 끊김	결측 사유

참고로 카드 파일의 업종명 일부에 글자 깨짐이 있습니다(예: '기타음식료품위주종합소매업'이 '?'가 섞인 이름으로 따로 집계됨). 분석에서는 원래 업종에 합쳤습니다.

이슈 1. 청소년 버스 무료화(2025-08-01) 시점의 측정 단절 의심

관측. 하루 평균 청소년 승차는 2025-07에 10,008명이었는데, 2025-08 3,203명, 09 1,938명, 10 1,812명으로 줄었습니다. 같은 기간 일반 승객은 30,949명에서 29,888명으로 거의 그대로였습니다. 같은 날 무료가 확대된 어린이도 909명에서 300명대로 줄었습니다.

측정 단절로 의심하는 근거 (판정관의 측정 단절 진단 기준):

근거	내용
방향 모순	무료화로 이용이 늘 것으로 기대되는데, 관측은 대조 집단 대비 −76%
비현실적 크기	정책 하나로 절반 넘게 줄어드는 것은 이례적
외부 통계 불일치	도 발표 누적 483만 건(2025-08~2026-02, 하루 약 22,783건)과 공개 데이터(2025-08~10, 청소년+어린이 하루 약 2,745명)가 8.3배 차이. 기간(도 발표는 학기 중 포함)과 단위(건 대 명, 환승은 건수만 늘림)가 달라 배수는 근사입니다. 다만 도가 밝힌 가장 낮은 수준인 방학 중(2026-01~02) 하루 2만 건 이상과 비교해도 약 7배 차이여서, 정의 차이만으로는 설명하기 어렵습니다
전환 모양	하루 만에 끊기지 않고 약 15일에 걸쳐 줄어듦. 교통복지카드 등록이 퍼지는 과정과 맞음
파일 간 일관성	정류소별 −76%, 노선별 −63%, 시간대별 −67%, 월별 패널티 −85%. 정책 대상이 아닌 경로·장애 유형에는 단절이 없음

근거	내용
시간대 모양	통학 시간대(07~09시)만이 아니라 새벽·밤까지 모든 시간대에서 일반 승객 대비 −60~−80%로 고르게 줄어듦. 이용 행동 변화보다 집계 누락에 가까운 모양

가설(미확인). 무료 승차가 공개 데이터의 집계에서 빠졌거나 다른 유형으로 분류되었을 수 있습니다.

판정관의 판정. 판정 보류(측정 체계 변경 의심).

확인 요청.

- 교통복지카드(무료) 승차 기록이 이용자 유형별 승차 자료에 들어가는지
- 2025-08-01 전후 이용자 유형 분류 기준이 바뀌었는지

이슈 2. 2025-01-01 '기타' 분류 신설과 어린이 감소

2025-01-01에 '기타' 이용자 유형이 처음 나타납니다(데이터 시작은 2019-01-01). 같은 날 어린이 승차는 대조 집단 대비 −52% 줄었습니다. 그리고 '기타'의 규모가 어린이 감소분의 103%입니다. 따라서 어린이 일부가 '기타'로 재분류된 것으로 의심합니다. 이 시점을 지나는 어린이 분석은 두 유형을 합쳐서 봐야 합니다.

이슈 3·4. 결측과 부분 집계

전체 결측. 2022-08-12 ~ 2022-11-23의 104일은 모든 이용자 유형의 행이 없습니다. 재개 직후 2022-11-24 ~ 12-07에는 합계가 평소의 0~41%인 날이 이어집니다.

짧은 부분 집계. 합계가 평소의 50% 미만이면서 집계 정류소 수도 80% 미만으로 줄어든 날이 117건(126일) 있습니다. 예를 들어 2024-06-20은 모든 시간대가 평소의 3% 수준입니다. 명절에는 정류소 수가 88~93%로 유지되므로 부분 집계와 구별됩니다.

판정관은 이런 날을 분석에서 자동으로 뺍니다. 하지만 일반 사용자가 엑셀로 전후를 비교하면 급감으로 보일 수 있습니다. 부분 집계일에 표시(플래그)를 붙여 주시면 오해를 줄일 수 있습니다.

이슈 5. 카드 파일 외국인 집단 결측

2023-05 ~ 06에 중국·일본·동남아·기타외국 4개 집단이 함께 비어 있습니다. 내국인·제주도민·법인은 있습니다. 사례 D(중국 단체관광 재개, 2023-08-10)의 처음 사전 등록 설계는 이 결측 때문에 사전 기간이 부족해 '판정 보류'가 되었습니다.

점검 방법과 정확도

- **점검 도구**: `jverdict.quality`. 하는 일은 세 가지입니다.
- 커버리지 점검: 전체·집단 결측, 부분 집계, 분류 신설
- 측정 단절 진단: 방향 모순, 비현실적 크기, 외부 통계 불일치, 분류 변경
- 시점을 모르는 단절 탐색
- **실행**: `python -m jverdict.cases.quality_real` → `outputs/cases/quality/real_quality.md`
- **정확도**: 정답을 심어 둔 합성데이터 2,600회로 측정했습니다.

항목	결과
측정 단절 탐지율(60~90% 누락)	100%
새 분류 신설 탐지율	100%
부분 집계일 재현율	99.7%
실제 효과를 측정 단절로 잘못 본 비율	0.125%
가장 약한 지점: 기존 분류 사이 이동	'의심' 11%, '확인 필요' 포함 67%

센터 활용 제안

1. **새 데이터를 올릴 때 자동 점검.** 같은 점검을 업로드 단계에서 돌리면, 집계 방식이 바뀐 날을 공개 전에 찾을 수 있습니다. 예: 이슈 1·2.
2. **품질 메모 공개.** 이용자 유형 신설, 결측 기간, 부분 집계일 같은 정보를 데이터 설명에 함께 실으면, 이 데이터를 쓰는 모든 분석의 오판을 줄일 수 있습니다.
3. **정책 판정 서비스와 연계.** 원인이 확인되거나 보완 자료가 나오면, 정책 판정관은 같은 사전 등록 설계로 다시 판정할 수 있습니다.

> 이 보고는 공개 데이터의 집계값만으로 작성했습니다. 개인을 알아볼 수 있는 정보는 쓰지 않았습니다. 원인은 단정하지 않았습니다.